

data

# Revisão de Álgebra Linear

João Guilherme Madeira Araújo  
*@\_joaogui1*




# Relembrando Vetores





# Relembrando vetores

É possível entender vetores de 3 maneiras:

- Pontos no espaço, ou segmentos da origem até esses pontos
- Listas de números em que podemos operar
- Qualquer conjunto que dê pra fazer combinações lineares







# Conjunto independente

- Um conjunto de vetores é dito independente quando nenhum deles é uma combinação linear dos outros
- Todo conjunto independente tem no máximo (dimensão do espaço) elementos
  - Exemplos:  $\{(1, 0), (0, 1)\}$ ,  $\{(1, 2), (1, 1)\}$
  - Não são:  $\{(1, 1), (2, 2)\}$ ,  $\{(0, 1), (1, 0), (1, 12)\}$ ,  $\{(0, 0), u, v\}$



# Span

- O span de um conjunto de vetores é o conjunto de todas as combinações lineares deles
- É a resposta para: “Quais vetores eu posso formar a partir desses aqui?”
- Um spanning set consegue gerar todos os vetores do seu espaço, todo spanning set tem pelo menos (dimensão do espaço) elementos
  - $\text{span}\{(1, 3)\} = \{(a, 3a), \text{ para todo } a \text{ real}\}$
  - $\{(1, 0), (0, 1)\}$  é um spanning set de  $\mathbb{R}^2$




# Base

- É um conjunto de vetores que representa de maneira única qualquer vetor do espaço
- São os “átomos” do seu espaço
- Toda base tem um número de elementos igual a (dimensão do espaço)
- Cada espaço tem infinitas bases







# Produto escalar

- Também chamado de produto interno, é uma operação que recebe dois vetores e retorna um número como resposta
- Algebricamente:  $x \cdot y = x_1 y_1 + x_2 y_2 + \dots x_n y_n$
- Geometricamente:  $\|x\| \|y\| \cos \theta$ 
  - $\|x\|^2 = x_1^2 + \dots x_n^2$
  - $\theta$  é o ângulo entre  $x$  e  $y$
- Dois vetores são ortogonais quando o seu produto escalar é 0





# Entendendo Matrizes



# Matrizes

É possível entender matrizes de 3 maneiras:


- Tabela de números
- Conjuntos de vetores
- Representação de uma transformação linear em uma base (transformação do espaço)



# Matrizes

Rotação de  $90^\circ$  no sentido horário

- Tabela de números
- Vetor  $[0, -1]$  e vetor  $[1, 0]$
- Se rotacionarmos o  $[1, 0]$  vamos parar no  $[0, -1]$ , e o  $[0, 1]$  vai para o  $[1, 0]$



# Produto matriz-vetor

- Estamos aplicando a transformação induzida pela matriz  $A$  no vetor  $v$
- Podemos também ver como uma combinação linear das colunas da matriz  $A$ , em que os coeficientes são os elementos de  $v$

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = x \begin{bmatrix} a \\ c \end{bmatrix} + y \begin{bmatrix} b \\ d \end{bmatrix}$$



# Matriz de mudança de base

- Como já vimos cada coluna de uma matriz é o efeito da transformação linear que ela representa nos vetores da base
- Quando as colunas da matriz formam uma base dizemos que ela é uma matriz de mudança de base, indo da base canônica para a base de seus vetores coluna

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = x \begin{bmatrix} a \\ c \end{bmatrix} + y \begin{bmatrix} b \\ d \end{bmatrix}$$



# Produto matriz-matriz

- É uma composição das transformações que cada uma das matrizes faz
- Também é o produto escalar entre as linhas da primeira e as colunas da segunda
- Por fim é o produto matriz-vetor da primeira matriz por cada uma das colunas da segunda

$$\begin{array}{c} \vec{a_1} \rightarrow \\ \vec{a_2} \rightarrow \end{array} \begin{array}{c} \vec{b_1} \quad \vec{b_2} \\ \downarrow \quad \downarrow \end{array} \begin{array}{c} \begin{bmatrix} 1 & 7 \\ 2 & 4 \end{bmatrix} \cdot \begin{bmatrix} 3 & 3 \\ 5 & 2 \end{bmatrix} = \begin{bmatrix} \vec{a_1} \cdot \vec{b_1} & \vec{a_1} \cdot \vec{b_2} \\ \vec{a_2} \cdot \vec{b_1} & \vec{a_2} \cdot \vec{b_2} \end{bmatrix} \\ A \qquad \qquad B \qquad \qquad C \end{array}$$







# Diagonalizando Matrizes



# Matrizes são complexas

- Uma matriz  $n$  por  $m$  tem  $nm$  números
- Isso torna a análise delas não trivial
- A computação de produtos custosa
- A exponenciação chata




# Matrizes diagonais são simples

- Tem apenas  $n$  números
- A transformação que ela representa é apenas um scaling das dimensões
- O produto é  $O(n)$
- Basta exponenciar cada um dos valores da diagonal individualmente



# Autovetores e autovalores

- São as soluções para  $Av = \lambda v$ 
  - Os  $v$  são os autovetores
  - Os  $\lambda$  são os autovalores associados
  - Os  $v$  são os vetores que a matriz age como se fosse apenas um scaling
- Para encontrar as soluções resolvemos a seguinte equação
  - $(A - I\lambda)v = 0$
  - $\det(A - I\lambda) = 0$



# Autovetores e autovalores

- Sejam  $v_1$  e  $v_2$  autovetores de  $A$  e  $\lambda_1$  e  $\lambda_2$  os respectivos autovalores
  - E suponha que eles formem uma base
- Queremos calcular  $Au$ 
  - $u = a_1 v_1 + a_2 v_2$
  - $Au = A(a_1 v_1 + a_2 v_2) = a_1 \lambda_1 v_1 + a_2 \lambda_2 v_2$
- Assim  $A$  age como uma matriz diagonal em  $u$  se  $u$  for escrito na base  $(v_1, v_2)$



# Diagonalização de matrizes

- No slide anterior
  - Encontramos os vetores em que a matriz age como scaling
  - Reescrevemos um vetor como uma combinação dos caras acima
  - Aplicamos o scaling nos autovetores
  - Voltamos o vetor para a base original
- Forma geral
  - Encontramos os autovalores e autovetores
  - Aplicamos uma matriz de mudança de base para a base composta pelos autovetores
  - Multiplicamos pela matriz diagonal
  - Desfazemos a mudança de base



# Eigendecomposition

- Matrizes cujos autovetores formam uma base podem ser diagonalizadas ou passar por uma eigendecomposition:
  - $A = Q^{-1}DQ$
  - $Q$  é a matriz de mudança de base para a eigenbasis
    - As colunas são os autovetores
  - $D$  é a matriz diagonal com os autovalores como entradas da diagonal
- Exemplos de coisas legais:
  - $A^n = (Q^{-1}DQ)(Q^{-1}DQ)\dots(Q^{-1}DQ) = Q^{-1}D^nQ$
  - $A^{-1} = (Q^{-1}DQ)^{-1} = Q^{-1}D^{-1}(Q^{-1})^{-1} = Q^{-1}(1/D)Q$



# Singular Value Decomposition






# E matrizes retangulares?

- Tudo o que fizemos até aqui foi para matrizes quadradas
  - Não temos um determinante para matrizes retangulares
- Mas muitas matrizes importantíssimas não são quadradas
- Daí que surge a ideia de valores singulares e vetores singulares



# Singular Value Decomposition

- $A = U\Sigma V^T$ 
  - $U$  é a matriz de vetores singulares esquerdos
  - $\Sigma$  é a matriz diagonal de valores singulares
  - $V$  é a matriz de vetores singulares direitos



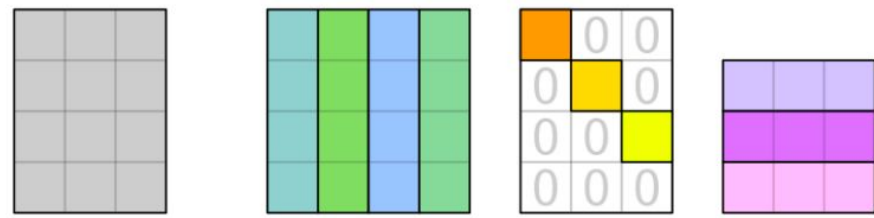
# Singular Value Decomposition

- $A = U\Sigma V^T$ 
  - $U^T U = I$
  - $V^T V = I$
  - $AV = U\Sigma$
- Como computar eles?
  - $A^T A = V\Sigma^2 V^T$ 
    - vs são os autovetores
    - $\sigma$ s são as raízes dos autovalores
  - $u_i = Av_i / \sigma_i$



# SVD - Interpretação

- $U$  é a matriz com a “base”
  - Os vetores de  $U$  serão combinados para gerar os vetores de  $A$
- $\Sigma$  é a importância de cada  $U$ 
  - $\sigma_1 > \sigma_2 > \dots > \sigma_m$
  - Dão a importância relativa de cada vetor de  $U$  (já que eles têm norma 1)
- $V$  é como combinamos os  $u$ 's para gerar os  $a$ 's
  - Cada  $u_i \sigma_i$  vai ser multiplicado por um elemento de  $v_j$  e somado para gerar o  $a_j$


$$\begin{matrix} \mathbf{M} \\ m \times n \end{matrix} = \begin{matrix} \mathbf{U} \\ m \times m \end{matrix} \begin{matrix} \mathbf{\Sigma} \\ m \times n \end{matrix} \begin{matrix} \mathbf{V}^* \\ n \times n \end{matrix}$$



# Aplicações

- Redução de dimensão
- Processamento de sinais
- Redução de ruído
- Compressão
- ...

